Pourquoi un alphabet plutôt que des mots ? Un modèle d’apprentissage itéré de la structure combinatoire des codas de cachalot

Loaï El Haj — L3 BISM, Université Claude Bernard Lyon 1

Octobre 2026 — rapport technique accompagnant github.com/loai-elhaj/whale-alphabet-emergence (traduction du rapport anglais)

Statut. Projet de licence, non évalué par des pairs. Le modèle est symbolique (pas d’audio) et teste la *plausibilité de mécanismes*, pas ce qui s’est réellement passé chez les cachalots. Tous les chiffres ci-dessous sont produits par le code du dépôt (graines fixées, résultats déterministes).

1. Résumé

Sharma et al. (2024) ont montré que les codas de cachalot combinent rythme, tempo, rubato et ornementation, ce qui donne un inventaire de signaux bien plus grand que les 21 types de codas décrits auparavant. Nous cherchons quelles pressions de transmission culturelle sont *suffisantes* pour qu’une telle structure combinatoire (« alphabet ») émerge dans un modèle minimal d’apprentissage itéré, plutôt qu’un répertoire de signaux holistiques sans lien entre eux (« mots »). Trois mécanismes ont été testés :

	Mécanisme	Résultat dans le modèle
H1	Goulot de transmission	**Confirmée.** La compositionnalité passe de 0,00 (sans goulot) à 0,64 (goulot 0,5) puis plafonne vers 0,70–0,72.
H2	Sélection sur la précision de communication	**Faible / non concluante.** La précision monte (0,88 à 0,97) mais à 40 générations la compositionnalité ne change pas de façon détectable ; un essai exploratoire à 150 générations montre un petit effet (+0,026, p = 0,022, non corrigé).
H3	Homophilie (apprendre surtout de son propre clan)	**Confirmée dans le modèle.** Une homophilie plus faible rend la structure propre à chaque clan plus rare et la compositionnalité plus basse ; la transition se situe entre homophilie 0,8 et 0,5.

H1 reproduit un résultat bien connu de la littérature sur l'apprentissage itéré (Kirby et al., 2008) ; l'apport ici est de l'appliquer à un espace de sens clan/unité/individu inspiré de la structure sociale des cachalots, et d'explorer H2 et H3 dans ce cadre.

2. Contexte biologique et ce que le modèle en reprend

Codas. Les codas sont des séquences stéréotypées de clics. Sharma et al. (2024) ont analysé 8 719 codas de cachalots des Caraïbes orientales (Dominica Sperm Whale Project) : les codas se regroupent en 18 types de rythme et 5 types de tempo, avec du rubato (variation graduelle de durée entre codas successives) et de l'ornementation (un clic final supplémentaire) ; au moins 143 combinaisons rythme/tempo sont fréquemment réalisées, contre 21 types de codas décrits auparavant. L'article montre une structure, pas un sens, et ne comporte pas d'expériences de playback.

Indices d'identité. Gero, Whitehead et Rendell (2016) ont étudié 4 116 codas de neuf unités sociales des Caraïbes et trouvé des indices d'identité aux niveaux de l'individu, de l'unité et du clan vocal. Les unités comptaient 4 à 12 individus (moyenne 8) et appartenaient toutes à un même clan vocal ; deux types de codas (« 1+1+3 » et « 5R1 ») représentaient 65 % des codas ; quatre unités utilisaient chacune un type distinctif à 4 clics. L'identification individuelle à partir de « 5R1 » fonctionnait au sein des unités (73–83 % dans les cas testés) mais mal en regroupant les unités (46 %). Dans le Pacifique, Rendell et Whitehead (2003) ont décrit plus de 70 types de codas mais seulement cinq clans vocaux (d'après Gero et al., 2016).

Ce que le modèle emprunte. La hiérarchie *clan* > *unité* > *individu* donne sa structure à l'espace de sens. C'est une **hypothèse de modélisation** : elle suppose que les signaux encodent l'identité, alors que Sharma et al. n'établissent pas ce que veulent dire les codas. Les tailles utilisées (6 clans × 5 unités × 11 individus = 330 sens) sont illustratives et **ne sont pas** des valeurs mesurées : la littérature du Pacifique rapporte cinq clans, les unités des Caraïbes comptent 4 à 12 membres (moyenne 8), et le nombre d'unités par clan est arbitraire.

3. Modèle

Sens et signaux. Un sens est un triplet (clan, unité, individu) avec (6, 5, 11) valeurs. Un signal est une chaîne de 6 lettres sur un alphabet de 6 lettres, formée de trois emplacements de 2 lettres, un par dimension.

Agents. Chaque agent possède (i) un *lexique*, les paires (sens → signal) exactes qu'il a observées, et (ii) une table de *chunks* associant une (dimension, valeur) à un emplacement de 2 lettres. Après observation d'exemples, un chunk est induit pour une (dimension, valeur) quand plus de 50 % des exemples observés partageant cette valeur portent le même emplacement (règle de majorité ; au moins 2 exemples).

Production. Pour un sens connu, l'agent rappelle l'entrée du lexique, copiée avec un bruit de 5 % par lettre. Pour un sens inconnu, il concatène les chunks des trois valeurs du sens ; un chunk manquant est inventé une fois puis conservé.

Générations. La génération 0 a un lexique aléatoire. Chaque agent suivant observe une fraction aléatoire (la *fraction de goulot*) des 330 signaux de l'agent précédent, apprend, puis produit le langage complet. On simule 40 générations ; les résultats sont pris à la dernière génération.

La compositionnalité est mesurée par la *similarité topographique* : la corrélation de rang de Spearman, sur toutes les paires de sens, entre la distance de Hamming des sens et la distance de Levenshtein de leurs signaux (rangs moyens pour les égalités). Un langage aléatoire donne environ 0 ; un langage parfaitement compositionnel s'approche de 1. Les **chunks appris** sont comptés juste après l'apprentissage, avant la production, pour que les chunks inventés à la production ne les gonflent pas (maximum 22 = 6 + 5 + 11).

Statistiques. Les scores de dernière génération sont comparés entre graines indépendantes par des tests de Mann–Whitney unilatéraux, avec correction de Bonferroni pour les comparaisons multiples.

4. H1 — Goulot de transmission

Prédiction. Un goulot plus serré force à généraliser ; la similarité topographique doit donc augmenter quand la fraction de goulot diminue. **Protocole.** Fractions 1,0 ; 0,7 ; 0,5 ; 0,3 ; 0,15 ; 20 graines chacune.

Goulot	Similarité topographique (moy. ± ét.-type)	Chunks appris (sur 22)
1,0 (aucun)	−0,001 ± 0,004	0,0
0,7	0,302 ± 0,065	10,6
0,5	0,636 ± 0,030	22,0
0,3	0,697 ± 0,035	21,9
0,15	0,717 ± 0,027	21,2

Comparaisons consécutives (unilatérales, Bonferroni $\alpha = 0{,}0125$) : 0,7 > 1,0, $p = 3{,}4\times10^{-8}$; 0,5 > 0,7, $p = 3{,}4\times10^{-8}$; 0,3 > 0,5, $p = 3{,}8\times10^{-6}$; 0,15 > 0,3, $p = 0{,}034$ (non significatif après correction).

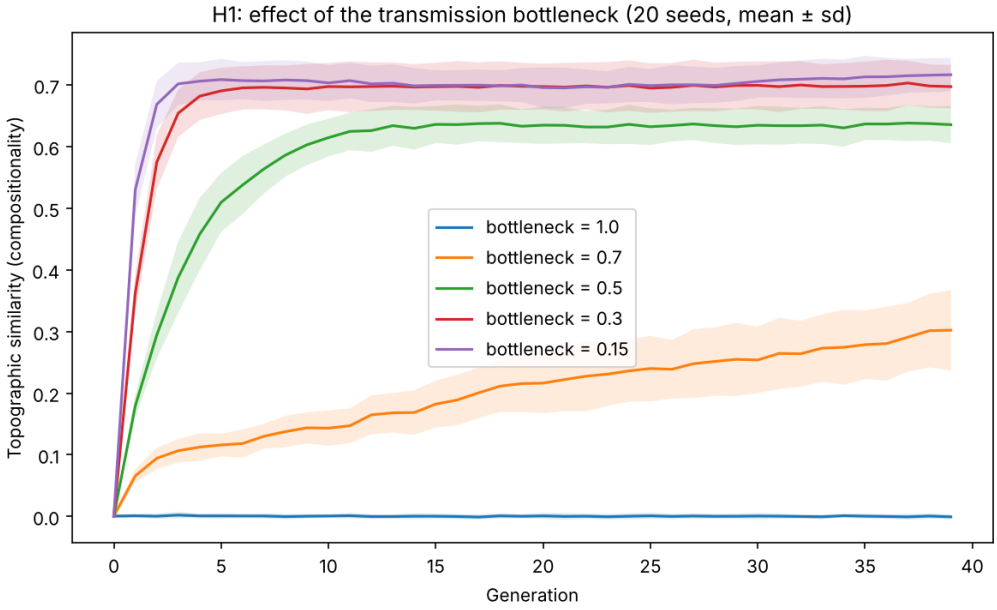


Figure 1: H1 : similarité topographique au fil des générations pour chaque goulot (moyenne ± écart-type sur 20 graines). Les légendes des figures sont en anglais.

Lecture. Sans goulot, chaque signal est simplement mémorisé et aucune structure n'apparaît. Avec un goulot, l'apprenant doit reconstruire les sens non vus à partir de chunks, et seuls les signaux compositionnels survivent à la transmission. Le gain sature quand presque les 22 chunks sont appris. **H1 est confirmée**, avec la réserve qu'il s'agit de l'effet classique de l'apprentissage itéré.

5. H2 — Sélection sur la précision de communication

Prédiction. Si les agents dont les signaux sont les moins ambigus sont favorisés, la compositionnalité devrait augmenter au-delà du seul effet du goulot. **Protocole.** À chaque génération, N candidats apprenants indépendants sont produits (chacun avec son propre échantillon aléatoire du goulot) ; on ne garde que celui de plus haute *précision de communication* (fraction des 330 sens dont le signal n'est partagé avec aucun autre sens). N ∈ {1, 3, 6, 10} ; N = 1 est la référence (identique à H1 à 0,7). Goulot 0,7 (la seule valeur testée qui n'était pas déjà au plafond) ; 20 graines.

Candidats	Similarité topographique	Chunks (sur 22)	Précision	p vs N = 1 (α = 0,0167)
1 (référence)	0,302 ± 0,065	10,6	0,879	—
3	0,321 ± 0,059	10,9	0,943	0,212
6	0,320 ± 0,062	11,3	0,970	0,182
10	0,317 ± 0,057	10,5	0,973	0,254

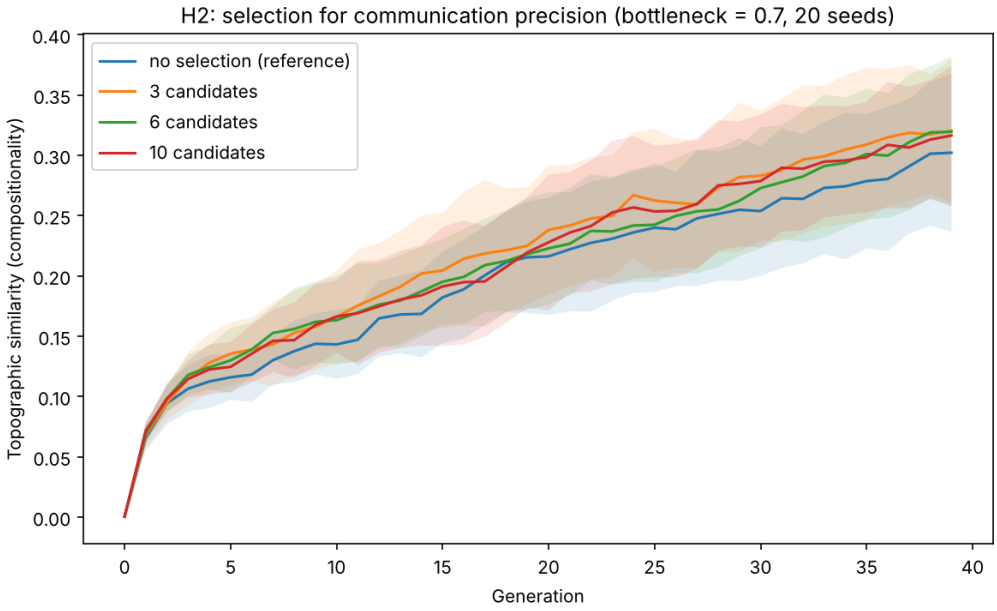


Figure 2: H2 : similarité topographique au fil des générations selon l'intensité de sélection (moyenne ± écart-type sur 20 graines).

Lecture. La sélection agit comme prévu (la précision passe de 0,88 à 0,97) mais à la génération 40 la compositionnalité ne change pas de façon détectable. Cela s'accorde avec l'idée qu'être non ambigu et être compositionnel sont deux propriétés différentes : un langage peut être précis simplement parce que ses signaux sont arbitraires et différents. Cependant, la figure 2 montre qu'à goulot 0,7 la compositionnalité monte encore à la génération 40 ; un effet de la sélection pourrait donc demander plus de temps.

Essai complémentaire long (exploratoire, lancé après avoir vu le résultat ci-dessus). Nous avons comparé 1 et 10 candidats sur 150 générations (20 graines chacun ; `run_h2_long.py`) : la similarité topographique à la dernière génération est de 0,495 ± 0,043 (sans sélection) contre 0,521 ± 0,040 (10 candidats), Mann–Whitney unilatéral p = 0,022. C'est un petit effet (environ +0,03), obtenu par une seule comparaison de suivi choisie après le résultat principal : il n'est

pas corrigé pour les tests multiples et doit être considéré comme suggestif. **Verdict pour H2 : aucun effet détectable à 40 générations ; au plus un petit effet dans des simulations plus longues.** L'enseignement principal est que, dans ce modèle, la sélection sur la précision est un moteur de compositionnalité bien plus faible que le goulot (H1).

6. H3 — Homophilie et différenciation entre clans

Prédiction. Si les apprenants tirent leurs exemples surtout de leur propre clan, chaque clan devrait stabiliser ses propres chunks (différenciation) ; quand les exemples viennent de plus en plus d'autres clans, dont les chunks diffèrent, la structure devrait devenir plus difficile à maintenir. **Protocole.** Six lignées de clans évoluent en parallèle, chacune sur ses propres 55 sens (5 unités × 11 individus). Pour chaque exemple d'apprentissage, avec probabilité *homophilie* il vient du propre clan de l'apprenant ; sinon d'un autre clan tiré au hasard (même couple unité/individu, signal produit par cet autre clan). Homophilie ∈ {1,0 ; 0,9 ; 0,8 ; 0,7 ; 0,6 ; 0,5 ; 0,3 ; 0,2} ; goulot 0,5 ; 30 graines par condition.

Trois mesures : (1) la similarité topographique moyenne sur les six clans ; (2) un *indice de différenciation*, défini seulement pour les valeurs (unité/individu) pour lesquelles au moins 4 clans sur 6 ont appris un chunk, comme la fraction de chunks distincts parmi ces clans (1 = chaque clan utilise son propre chunk) ; (3) la *probabilité de formation de structure*, fraction de graines où au moins une valeur remplit ce critère (définie pour toutes les graines).

Homophilie	Similarité topographique	Indice de différenciation	Graines avec indice défini (sur 30)	P(structure se forme)
1,0	0,555	0,939	30	1,00
0,9	0,435	0,926	30	1,00
0,8	0,353	0,905	29	0,97
0,7	0,255	0,822	22	0,73
0,6	0,218	0,880	15	0,50
0,5	0,195	0,559	10	0,33
0,3	0,168	0,333	3	0,10
0,2	0,161	0,375	4	0,13

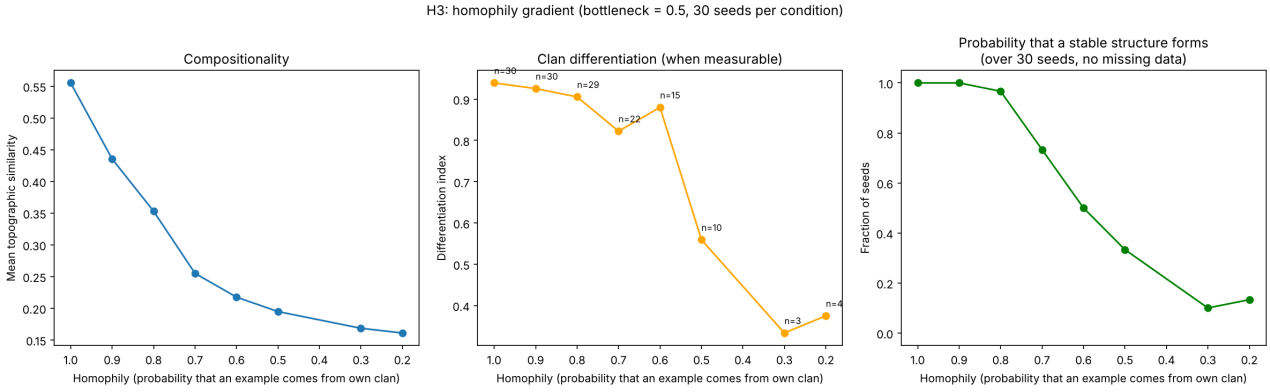


Figure 3: H3 : trois mesures en fonction de l'homophilie (30 graines par condition).

Lecture. La compositionnalité décroît de façon monotone quand l'homophilie faiblit, et la probabilité que la structure propre aux clans se forme passe sous 50 % entre l'homophilie 0,7 et 0,6. L'indice de différenciation n'est fiable que tant que assez de graines sont qualifiées

(jusqu'à l'homophilie 0,6) ; en dessous, il repose sur 3 à 10 graines et est sélectionné sur la condition même (la formation de structure) qu'il est censé mesurer : il est donc indicatif. **H3 est confirmée dans le modèle.** Mécaniquement, les clans inventent des chunks différents ; mélanger les exemples entre clans donne donc des indices contradictoires et la règle de majorité ne parvient plus à consolider les chunks. C'est une propriété de la règle d'apprentissage du modèle, pas une preuve directe sur les vrais cachalots. Notons aussi que les scores de H3 sont calculés sur 55 sens par clan (une dimension fixe) et **ne sont pas directement comparables** aux scores à 330 sens de H1 et H2.

7. Validation et pièges de conception rencontrés

Les documenter fait partie du résultat, car chacun a changé des chiffres.

1. **L'unanimité stricte n'apprenait rien.** La première règle d'induction de chunks (tous les exemples doivent concorder) produisait zéro chunk avec 5 % de bruit de copie ; elle a été remplacée par une règle de majorité.
2. **La priorité aux chunks a causé une régression.** Une version précoce donnait la priorité aux chunks sur le lexique à la production, ce qui faisait « apprendre » les 22 chunks quelle que soit la condition. Elle a été retirée ; un test de référence (goulot 0,7, graine 0 → 10 chunks) protège contre son retour. Une réintroduction accidentelle a ensuite invalidé un passage de H2/H3, écarté quand le test a échoué.
3. **Mesurer les chunks trop tard.** Les chunks comptés après la production incluent des chunks inventés. Le nombre de chunks (H1/H2) et la différenciation (H3) sont maintenant capturés juste après l'apprentissage.
4. **L'isolement total était un test peu informatif pour H3.** Sans information partagée entre clans, des lignées indépendantes divergent presque sûrement (deux emplacements aléatoires de 2 lettres coïncident avec probabilité 1/36 pour un alphabet de 6 lettres) ; remplacé par le gradient d'homophilie.
5. **Égalités dans la corrélation de Spearman.** La première implémentation classait avec un simple `argsort`. Les distances de Hamming ne prennent que 4 valeurs et celles de Levenshtein 7 : les égalités sont massives, et leur départage arbitraire biaisait les scores vers le haut (référence d'un langage aléatoire à 0,04 au lieu de 0) et rendait les résultats dépendants de la machine (la même graine donnait des scores différents sur deux ordinateurs). Il a été remplacé par des rangs moyens. Après correction, tous les nombres de chunks, précisions, indices de différenciation et probabilités de formation étaient identiques à ceux obtenus avant ; seules les similarités topographiques ont changé, sans modifier aucune conclusion.

8. Limites

- **Signaux symboliques.** Pas d'acoustique ; la segmentation en 3 emplacements est imposée et non découverte. Un modèle plus proche des données devrait apprendre la segmentation (et les dimensions rythme, tempo, rubato, ornementation) à partir de l'audio.
- **Espace de sens supposé.** On suppose que les codas encodent l'identité (clan/unité/individu) ; leur contenu informationnel réel est inconnu. Les tailles sont illustratives.
- **Conditions uniques.** H2 a été testée à goulot 0,7 et H3 à 0,5 ; pas de croisement factoriel complet.
- **Mécanismes simplifiés.** La sélection porte seulement sur l'unicité stricte des signaux ; l'homophilie est un choix binaire propre clan/autre clan sans proximité sociale graduée ; pas de composante génétique (les codas sont transmises culturellement).
- **H2 faiblement évaluée.** Aucun effet à 40 générations (n = 20) ; un petit effet dans un essai post hoc à 150 générations. D'autres formes de sélection n'ont pas été testées, et un plan plus long, défini à l'avance, serait nécessaire pour trancher.

- **Pas de correspondance quantitative avec les données réelles.** Nous ne prétendons pas que des quantités du modèle (p. ex. 330 sens à partir de 22 chunks) correspondent à des quantités empiriques (p. ex. ≥143 combinaisons à partir de 18 rythmes et 5 tempos).

9. Reproductibilité

Python 3, `numpy`, `scipy`, `matplotlib`. Les scripts `run_h1_bottleneck.py`, `run_h2_selection.py`, `run_h3_homophily.py` (et `run_h2_long.py`) régénèrent chaque tableau et chaque figure (environ 7 minutes au total sur un portable ; `run_h2_long.py` ajoute environ 3 minutes) ; `make_summary_figure.py` reconstruit la figure de synthèse. Les graines sont fixées (0–19 pour H1/H2, 0–29 pour H3).

Références

- Cantor, M., Shoemaker, L. G., Cabral, R. B., Flores, C. O., Varga, M., & Whitehead, H. (2015). Multilevel animal societies can emerge from cultural transmission. *Nature Communications*, 6.
- Gero, S., Whitehead, H., & Rendell, L. (2016). Individual, unit and vocal clan level identity cues in sperm whale codas. *Royal Society Open Science*, 3, 150372.
- Kirby, S., Cornish, H., & Smith, K. (2008). Cumulative cultural evolution in the laboratory: an experimental approach to the origins of structure in human language. *PNAS*, 105.
- Rendell, L., & Whitehead, H. (2003). Vocal clans in sperm whales (*Physeter macrocephalus*). *Proceedings of the Royal Society B*, 270.
- Sharma, P., Gero, S., Payne, R., Gruber, D. F., Rus, D., Torralba, A., & Andreas, J. (2024). Contextual and combinatorial structure in sperm whale vocalisations. *Nature Communications*, 15, 3617.